## Metode Numerice @ CS-UPB

Echipa MN CS - 2015:

Profesori:

- Pantelimon George Popescu - Seria CA;
- Florin Pop - Seria CB, CC;

Asistenti:

PG Popescu, Clementin Cercel, Sorin Ciolofan, Bogdan Tiganoaia, Diana Udrea, Alexandru Tifrea, David Iancu, Bogdan Cristian Marchis, Radu Poenaru, Madalina Grosu, Andrei Vlad Postoaca, Radu Constantinescu, Roxana Istrate, Madalina Hristache, Adelina Vidovici;



## Metode Iterative/Aproximative pt. SEL






## Metode Iterative

Un sistem linear mare Ax=b este indicat sa fie rezolvat prin metode iterative atunci cand matricea coeficientilor A este dominant diagonala.

Vom prezenta cateva metode iterative, ca Jacobi, Gauss-Seidel, Successive-over-relaxation(SOR), etc.

Metodele iterative pornesc de la o solutie initiala aleasa x0 si genereaza o alta solutie x1, mai buna care se bazeaza pe reducerea diferentei dintre solutia xk, la pasul k si solutia xk-1, de la pasul anterior.



## Metode Iterative

Procedura se repeta pana converge catre solutia reala. Metoda este convergenta daca la fiecare pas se apropie cat mai mult de solutia reala a sistemului, si deci cu cat iteram mai mult cu atat ne apropiem mai mult de solutie.

Aceste metode nu converg pentru toate SEL. O conditie suficienta pentru convergenta unei metode iterative de solutionare SEL este diagonal-dominanta matricei coeficientilor, pentru orice vector solutie ales initial.



## Metode Iterative

Procedura se repeta pana se atinge un anumit criteru de convergenta. Daca metoda, la un moment dat produce o modificare nesemnificativa a vectorului solutie, metoda trebuie oprita. De asemenea metoda se opreste daca o marime a modificarii, relative sau absolute, vectorului solutie este mai mica dacat un criteriu de convergenta specificat.



## Metode Iterative

Jacobi (Carl Gustav Jacob Jacobi (1804 - 1851) matematician german)

Rescriem un sistem SEL Ax=b in forma

$$\sum_{j=1}^{n} a_{ij}x_j = b_i \qquad (i = 1, 2, \ldots, n)$$

Metoda considera la fiecare pas elementul necunoscut xi asociat elementului diagonal de la resp pas.

## Metode Iterative

si deci

$$x_i = \frac{1}{a_{i,i}}\left(b_i - \sum_{j=1}^{i-1} a_{i,j}x_j - \sum_{j=i+1}^{n} a_{i,j}x_j\right) \qquad (i = 1, 2, \ldots, n)$$

Considerand x^(0) solutie initiala, il vom calcula pe x^(1)_i in functie de x^(0) astfel

$$x_i^{(1)} = \frac{1}{a_{i,i}}\left(b_i - \sum_{j=1}^{i-1} a_{i,j}x_j^{(0)} - \sum_{j=i+1}^{n} a_{i,j}x_j^{(0)}\right) \qquad (i = 1, 2, \ldots, n)$$



## Metode Iterative

si general pentru un pas oarecare k

$$x_i^{(k+1)} = \frac{1}{a_{i,i}}\left(b_i - \sum_{j=1}^{i-1} a_{i,j}x_j^{(k)} - \sum_{j=i+1}^{n} a_{i,j}x_j^{(k)}\right) \qquad (i = 1, 2, \ldots, n)$$

Si mai departe adunand si scazand a_iix_i^(k) avem

$$x_i^{(k+1)} = x_i^{(k)} + \frac{1}{a_{i,i}}\left(b_i - \sum_{j=1}^{n} a_{i,j}x_j^{(k)}\right) \qquad (i = 1, 2, \ldots, n)$$



## Metode Iterative

Ultima ecuatie se poate pune si sub forma

$$x_i^{(k+1)} = x_i^{(k)} + \frac{R_i^{(k)}}{a_{i,i}} \qquad (i = 1, 2, \ldots, n)$$

$$R_i^{(k)} = b_i - \sum_{j=1}^{n} a_{i,j}x_j^{(k)} \qquad (i = 1, 2, \ldots, n)$$

R_i^(k) reprezentand restul ecuatiei i.



## Metode Iterative

Acuratetea si Convergenta metodelor iterative

Metodele iterative sunt mai putin vulnerabile la erorile de rotunjire deoarece: 1. sistemul este dominant diagonal; 2. de obicei sistemul este sparse; 3. fiecare iteratie nu este afectata de erorile de rotunjire de la precedenta iteratie;

Termenul de acuratete asociat metodelor iterative se refera la numarul de zecimale obtinut/dorit in calcule, iar convergenta se refera la pasul de iteratie cand acuratetea a fost atinsa.



## Metode Iterative

Acuratetea metodelor iterative este masurata raportat la eroarea metodei, ce poate fi specificata in doua feluri: eroare absoluta si eroare relativa, astfel

EroareaAbsoluta = ValoareaAprox - ValoareaExacta
EroareaRelativa = EroareaAbsoluta/ValoareaExacta



## Metode Iterative

Convergenta metodelor iterative este atinsa cand un criteriu de acuratete a fost satisfacut.

Pentru ca nu se cunoaste valoarea exacta a solutiei, eroarea este masurata la fiecare pas ca fiind diferenta dintre ce s-a obtinut la respectivul pas fata de precedentul. Cateva criterii de convergenta se practica:

- Eroare Absoluta $|(\Delta x_i)_{\max}| \le \varepsilon$ $\sum_{i=1}^{n}|\Delta x_i| \le \varepsilon$ $\left[\sum_{i=1}^{n}(\Delta x_i)^2\right]^{1/2} \le \varepsilon$
- Eroare Relativa $\left|\frac{(\Delta x_i)_{\max}}{x_i}\right| \le \varepsilon$ $\sum_{i=1}^{n}\left|\frac{\Delta x_i}{x_i}\right| \le \varepsilon$ $\left[\sum_{i=1}^{n}\left(\frac{\Delta x_i}{x_i}\right)^2\right]^{1/2} \le \varepsilon$

## Metode Iterative

Gauss-Seidel (Johann Carl Friedrich Gauss (1777-1855) matematician si fizician german) - (Philipp Ludwig von Seidel (1821-1896) matematician german)

Daca la Jacobi toate valorile vectorului x^(k+1) se calculau in functie de x^(k), aici valorile vectorului x^(k+1) se calculeaza in functie de cele care au fost calculate deja in pasul respectiv si de cele ramase din pasul precedent, adica



## Metode Iterative

$$x_i^{(k+1)} = \frac{1}{a_{i,i}}\left(b_i - \sum_{j=1}^{i-1} a_{i,j}x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{i,j}x_j^{(k)}\right) \qquad (i = 1, 2, \ldots, n)$$

Si considereand resturi, rescriem astfel:

$$x_i^{(k+1)} = x_i^{(k)} + \frac{R_i^{(k)}}{a_{i,i}} \qquad (i = 1, 2, \ldots, n)$$

$$R_i^{(k)} = b_i - \sum_{j=1}^{i-1} a_{i,j}x_j^{(k+1)} - \sum_{j=i}^{n} a_{i,j}x_j^{(k)} \qquad (i = 1, 2, \ldots, n)$$



## Metode Iterative

Successive Over Relaxation (SOR - 1950) ((David M. Young Jr. (1923 - 2008) matematician si calculatorist american, si H. Frankel) dar si mai inainte de (Lewis Fry Richardson(1881-1953) matematician, fizician, meteorolog si psiholog englez si Richard Vynne Southwell(1888 - 1970) matematician englez-mecanica aplicata))



## Metode Iterative

### Successive Over Relaxation

Se inmulteste result R_i^(k) cu un factor w (aceste metode se mai numesc metode de relaxare) si deci metoda se prezinta astfel

$$x_i^{(k+1)} = x_i^{(k)} + \omega\frac{R_i^{(k)}}{a_{i,i}} \qquad (i = 1, 2, \ldots, n)$$

$$R_i^{(k)} = b_i - \sum_{j=1}^{i-1} a_{i,j}x_j^{(k+1)} - \sum_{j=i}^{n} a_{i,j}x_j^{(k)} \qquad (i = 1, 2, \ldots, n)$$

Se observa ca pentru w=1 -> SOR = Gauss-Seidel. Pentru 1<w<2 sistemul este over-relaxed si de obicei se foloseste la SEL;



## Metode Iterative

### Successive Over Relaxation

Pentru w<1 sistemul este under-relaxed si de obicei se foloseste la SEL atunci cand Gauss-Seidel se departeaza de solutie, dar de obicei se foloseste la Sisteme de Ecuatii Nelineare;

Pentru w>=2 metoda este divergenta.

Acest factor w nu perturba solutia deoarece la finalul procesului de iteratie restul R_i^(k) este aproape 0 si deci inmultit cu ceva tot aproximativ 0 ramane.



## Metode Iterative

### Successive Over Relaxation

Problema acestei metode ramane selectia lui w optim astfel incat metoda sa convearga mai repede. Din nefericire nu exista metode de selectare pentru w optim si deci nu are rost sa folosim o astfel de metoda punctual ci doar daca avem spre exemplu de calculat mai multe solutii pentru mai multi vectori, b termeni liberi (avand aceasi matrice a coeficientilor). Si dupa cateva alegeri ale lui w, testand convergenta, alegem w optim si il folosim pentru restul de SEL(restul de vectori b).

## Metode Iterative

### Forma Generala a Metodelor Iterative

Putem rescrie Ax=b astfel x=(I-A)x+b, adica x=Tx+b.

$$\mathbf{x}_{k+1} = (I - A)\mathbf{x}_k + \mathbf{b}.$$

Iar daca A=M-N, atunci sistemul devine

x=M^-1Nx+M^-1b

$$M\mathbf{x}_{k+1} = N\mathbf{x}_k + \mathbf{b}.$$

si sistemul

Mz=r este mai usor de rezolvat decat Ax=b.



## Metode Iterative

### Forma Generala a Metodelor Iterative

Convergenta este data de valorile proprii ale lui

$$M^{-1}N = I - M^{-1}A$$

adica metroda converge data valorile proprii ale matricei de iteratie M^-1N, sunt mai mici ca 1 si cu cat sunt mai mici cu atat converge mai repede.



## Metode Iterative

### Forma Generala a Metodelor Iterative

este data de formula

$$\mathbf{x}^{(k)} = T\mathbf{x}^{(k-1)} + \mathbf{c}.$$

unde pentru Jacobi A=D-L-U=D-(L+U) si deci

$$\mathbf{x} = D^{-1}(L + U)\mathbf{x} + D^{-1}\mathbf{b}.$$

de unde $T_j = D^{-1}(L + U)$ si $\mathbf{c}_j = D^{-1}\mathbf{b}$



## Metode Iterative

### Forma Generala a Metodelor Iterative

Iar pentru Gauss-Seidel, unde A=D-L-U=(D-L)-U

$$\mathbf{x}^{(k)} = (D - L)^{-1}U\mathbf{x}^{(k-1)} + (D - L)^{-1}\mathbf{b}$$

de unde $T_g = (D-L)^{-1}U$ si $\mathbf{c}_g = (D-L)^{-1}\mathbf{b}$

Iar pentru SOR, unde

A=w(D-L-U)=(D-wL)-[(1-w)D+wU]

$$\mathbf{x}^{(k)} = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]\mathbf{x}^{(k-1)} + \omega(D - \omega L)^{-1}\mathbf{b}.$$

de unde $T_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$

iar $\mathbf{c}_\omega = \omega(D - \omega L)^{-1}\mathbf{b}$



## Metode Iterative

### Metoda Gradientului Conjugat

(Magnus Rudolph Hestenes (1906-1991) mat. american si Eduard L. Steifel (1907-1998) mat. elvetian)

Retinem produsul scalar si ale sale proprietati $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^t\mathbf{y}$

O matrice este semipozitiv definita SPD daca x^TAx>0 pentru orice x diferit de 0, ie $\langle \mathbf{x}, A\mathbf{x} \rangle = \mathbf{x}^t A\mathbf{x} > 0$

x* este solutie pentru sistemul SPD Ax=b daca si numai daca x* minimizeaza

$$g(\mathbf{x}) = \langle \mathbf{x}, A\mathbf{x} \rangle - 2\langle \mathbf{x}, \mathbf{b} \rangle.$$



## Metode Iterative

### Metoda Gradientului Conjugat

Sau echivalent, se doreste x care minimizeaza

$$\phi(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T A\mathbf{x} - \mathbf{b}^T\mathbf{x}.$$

Fie x o solutie aproximativa initiala pentru sistemul Ax*=b si v diferit de 0, o directie de cautare(adica in ce parte ma deplasez fata de x pentru cautarea solutiei), consideram r=b-Ax, vector reziduu si

$$t = \frac{\langle \mathbf{v}, \mathbf{b} - A\mathbf{x} \rangle}{\langle \mathbf{v}, A\mathbf{v} \rangle} = \frac{\langle \mathbf{v}, \mathbf{r} \rangle}{\langle \mathbf{v}, A\mathbf{v} \rangle}.$$

## Metode Iterative
### Metoda Gradientului Conjugat

Daca r este diferit de 0 si r,v nu sunt ortogonali, atunci g(x+tv)<g(x), ceea ce inseamna ca x+tv este mai aproape de x* decat x.

Si de aici deducem metoda.

Fie x(0) o aproximatie initiala a lui x* si fie v(1) o directie de cautare initiala, atunci pentru k=1,2,... calculam

$$t_k = \frac{\langle \mathbf{v}^{(k)}, \mathbf{b} - A\mathbf{x}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle},$$
$$\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + t_k \mathbf{v}^{(k)}$$

si alegem noua directie de cautare v(k+1).



## Metode Iterative
### Metoda Gradientului Conjugat

Pentru alegerea directiei de cautare v(k+1), consideram functia g(x)=g(x1,x2,...,xn)

$$g(x_1, x_2, \ldots, x_n) = \langle \mathbf{x}, A\mathbf{x} \rangle - 2\langle \mathbf{x}, \mathbf{b} \rangle = \sum_{i=1}^{n} \sum_{j=1}^{n} a_{ij} x_i x_j - 2 \sum_{i=1}^{n} x_i b_i.$$

Directia de cautare este, in sensul in care vreau ca g(x) sa descreasca cu fiecare pas, data de

$$-\nabla g(\mathbf{x})$$



## Metode Iterative
### Metoda Gradientului Conjugat

Cum $\frac{\partial g}{\partial x_k}(\mathbf{x}) = 2\sum_{i=1}^{n} a_{ki} x_i - 2b_k,$ atunci

$$\nabla g(\mathbf{x}) = \left( \frac{\partial g}{\partial x_1}(\mathbf{x}), \frac{\partial g}{\partial x_2}(\mathbf{x}), \ldots, \frac{\partial g}{\partial x_n}(\mathbf{x}) \right)^t = 2(A\mathbf{x} - \mathbf{b}) = -2\mathbf{r},$$

deci directia este data de vectorul r.

$$\mathbf{v}^{(k+1)} = \mathbf{r}^{(k)} = \mathbf{b} - A\mathbf{x}^{(k)}$$

Pentru aceasta alegere metoda poarta numele de metoda de pasi descrescatori.



## Metode Iterative
### Metoda Gradientului Conjugat

Desi metoda cu pasi descrescatori este buna pentru sisteme de ecuatii nelineare sau pentru probleme de optimizare, in cazul SEL aceasta metoda nu se foloseste deoarece are convergenta slaba.

O alternativa pentru alegerea directiilor de cautare ar fi ca vectorii $\{\mathbf{v}^{(1)}, \ldots, \mathbf{v}^{(n)}\}$ sa satisfaca A-ortogonalitatea, adica

$$\langle \mathbf{v}^{(i)}, A\mathbf{v}^{(j)} \rangle = 0,$$ i≠j.



## Metode Iterative
### Metoda Gradientului Conjugat

Atunci $t_k = \frac{\langle \mathbf{v}^{(k)}, \mathbf{b} - A\mathbf{x}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle} = \frac{\langle \mathbf{v}^{(k)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle}$ iar $\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + t_k \mathbf{v}^{(k)}.$

Daca v(k) sunt astfel alesi, iar A este SPD atunci Ax(n)=b, adica se atinge solutia exacta dupa exact n pasi.



## Metode Iterative
### Metoda Gradientului Conjugat

Aceasta alegerea a vectorilor directii de cautare se numeste metoda directiei conjugate.

Intre vectorii reziduu si vectorii directie avem ortogonalitate, ie pentru orice k=1,2,...n, $\langle \mathbf{r}^{(k)}, \mathbf{v}^{(j)} \rangle = 0,$ pentru orice j=1,2,...k.

## Metode Iterative
### Metoda Gradientului Conjugat

Metoda Gradientului Conjugat alege directiile de cautare astfel incat vectorii reziduu sa fie ortogonali intre ei. Procedam astfel:

sa spunem ca am ajuns la pasul k si deci v(1),...,v(k-1) si x(0),...,x(k-1) au fost calculati astfel $\mathbf{x}^{(k-1)} = \mathbf{x}^{(k-2)} + t_{k-1}\mathbf{v}^{(k-1)}$ unde $\langle \mathbf{v}^{(i)}, A\mathbf{v}^{(j)} \rangle = 0$ $\langle \mathbf{r}^{(i)}, \mathbf{r}^{(j)} \rangle = 0,$ $i \neq j.$

Acum daca x(k-1) verifica Ax=b, ne oprim, daca nu atunci $\mathbf{r}^{(k-1)} = \mathbf{b} - A\mathbf{x}^{(k-1)} \neq \mathbf{0}$





## Metode Iterative
### Metoda Gradientului Conjugat

Stim ca $\langle \mathbf{r}^{(k-1)}, \mathbf{v}^{(i)} \rangle = 0$ pentru i=1,2,...,k-1 si ne folosim de r(k-1) pentru a obtine vectorul directie v(k)

$$\mathbf{v}^{(k)} = \mathbf{r}^{(k-1)} + s_{k-1}\mathbf{v}^{(k-1)}.$$

$$A\mathbf{v}^{(k)} = A\mathbf{r}^{(k-1)} + s_{k-1}A\mathbf{v}^{(k-1)}$$

$$\langle \mathbf{v}^{(k-1)}, A\mathbf{v}^{(k)} \rangle = \langle \mathbf{v}^{(k-1)}, A\mathbf{r}^{(k-1)} \rangle + s_{k-1}\langle \mathbf{v}^{(k-1)}, A\mathbf{v}^{(k-1)} \rangle,$$

Si vrem ca ultima sa fie 0, deci rezulta s_k-1

$$s_{k-1} = -\frac{\langle \mathbf{v}^{(k-1)}, A\mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k-1)}, A\mathbf{v}^{(k-1)} \rangle}.$$





## Metode Iterative
### Metoda Gradientului Conjugat

Deci il avem pe v(k), trecem la t(k)

$$t_k = \frac{\langle \mathbf{v}^{(k)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle} = \frac{\langle \mathbf{r}^{(k-1)} + s_{k-1}\mathbf{v}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle}$$

$$= \frac{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle} + s_{k-1}\frac{\langle \mathbf{v}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle}.$$

dar $\langle \mathbf{v}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle = 0,$ atunci $t_k = \frac{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle}.$

Si deci $\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + t_k\mathbf{v}^{(k)}.$





## Metode Iterative
### Metoda Gradientului Conjugat

Sau $A\mathbf{x}^{(k)} - \mathbf{b} = A\mathbf{x}^{(k-1)} - \mathbf{b} + t_kA\mathbf{v}^{(k)}$ de unde rezulta

$$\mathbf{r}^{(k)} = \mathbf{r}^{(k-1)} - t_kA\mathbf{v}^{(k)}.$$

$$\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle = \langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k)} \rangle - t_k\langle A\mathbf{v}^{(k)}, \mathbf{r}^{(k)} \rangle = -t_k\langle \mathbf{r}^{(k)}, A\mathbf{v}^{(k)} \rangle.$$

si inlocuind tk obtinem $\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle = t_k\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle,$

de unde $s_k = -\frac{\langle \mathbf{v}^{(k)}, A\mathbf{r}^{(k)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle} = -\frac{\langle \mathbf{r}^{(k)}, A\mathbf{v}^{(k)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle} = \frac{(1/t_k)\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{(1/t_k)\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle} = \frac{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}.$





## Metode Iterative
### Metoda Gradientului Conjugat

Pe scurt $\mathbf{r}^{(0)} = \mathbf{b} - A\mathbf{x}^{(0)};$ $\mathbf{v}^{(1)} = \mathbf{r}^{(0)};$

Pentru k=1,2,...,n

$$t_k = \frac{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle}, \quad \mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + t_k\mathbf{v}^{(k)}, \quad \mathbf{r}^{(k)} = \mathbf{r}^{(k-1)} - t_kA\mathbf{v}^{(k)}, \quad s_k = \frac{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle},$$

si $\mathbf{v}^{(k+1)} = \mathbf{r}^{(k)} + s_k\mathbf{v}^{(k)}.$





## Metode Iterative
### Preconditionare

Daca matricea A este rau conditionata atunci metoda iterativa este supusa la erori de rotunjire. Metoda nu este aplicata direct matricei A ci unei alte matrici, tot SPD, dar cu un numar de conditionare mai mic.

Preconditionarea inlocuieste sitemul initial cu un altul, ce are aceasi solutie dar care are conditii mai bune pentru convergenta.



## Metode Iterative

### Preconditionare

Ca sa pastram proprietatea de SPD, inmultim in ambele parti sistemul cu o matrice C^-1, nesingulara. Consideram A~ $\tilde{A} = C^{-1}A(C^{-1})^t$ si speram ca are un numar de conditionare mai mic ca A.

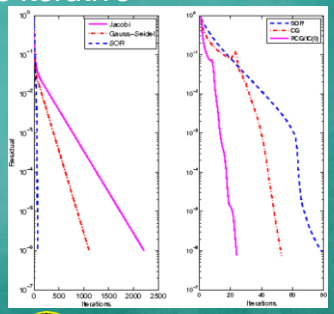
Noul sistem va fi $\tilde{A}\tilde{\mathbf{x}} = \tilde{\mathbf{b}}$, cu $\tilde{\mathbf{x}} = C^t\mathbf{x}$ si $\tilde{\mathbf{b}} = C^{-1}\mathbf{b}$.

$$\tilde{A}\tilde{\mathbf{x}} = (C^{-1}AC^{-t})(C^t\mathbf{x}) = C^{-1}A\mathbf{x}.$$

Si rezolvam sistemul pentru x~ si apoi inmultiind cu $C^{-t} \equiv (C^{-1})^t$ obtinem x.



## Metode Iterative






## Bibliografie Metode Iterative SEL


- Chen Greif, Numerical Solution of Linear Systems, Department of Computer Science, The University of British Columbia, Vancouver B.C., Tel Aviv University, December 17, 2008
- Richard L. Burden, J. Douglas Faires, Numerical Analysis, 9th edition, Brooks/Cole, Cengage Learning, 2011;