Lab 2 MN - LU, SST, SIT, Inversare prin partitionare

$Ax = b$ $\quad A = m \times n \quad X = n \times 1 \quad b = m \times 1$

I. SST $\Rightarrow A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ 0 & a_{22} & \dots & a_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \dots & a_{nn} \end{bmatrix}$ - sup. triunghi.

$A = n \times n$

$$A \cdot \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

$a_{nn} \cdot x_n = b_n$

$a_{n-1,n} \cdot x_n + a_{n-1,n-1} \cdot x_{n-1} = b_{n-1}$

$$x_i = \frac{b_i - \sum_{k=i+1}^{n} a_{ik} \cdot x_k}{a_{ii}}$$

II. SIT $\Rightarrow A = \begin{bmatrix} a_{11} & 0 & \dots & 0 \\ a_{21} & a_{22} & \dots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}$ - inf. tr.

$a_{11} \cdot x_1 = b_1$

$a_{21} \cdot x_1 + a_{22} \cdot x_2 = b_2$

$$x_i = \frac{b_i - \sum_{k=1}^{i-1} a_{ik} \cdot x_k}{a_{ii}}$$

III. LU $\quad A = LU \Rightarrow LUx = b \begin{cases} Ux = y \rightarrow SST \\ Ly = b \rightarrow SIT \end{cases}$

(y = n)

III. 1) Crout ($u_{ii} = 1$)

$$A = \begin{bmatrix} 2 & -1 & 3 \\ 4 & 5 & 1 \\ 2 & 1 & 2 \end{bmatrix} = L \cdot U = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \cdot \begin{bmatrix} 1 & u_{12} & u_{13} \\ 0 & 1 & u_{23} \\ 0 & 0 & 1 \end{bmatrix}$$

$$\Rightarrow \begin{bmatrix} l_{11} & l_{11}\cdot u_{12} & l_{11}\cdot u_{13} \\ l_{21} & l_{21}\cdot u_{12} + l_{22} & l_{21}\cdot u_{13} + l_{22}\cdot u_{23} \\ l_{31} & l_{31}\cdot u_{12} + l_{32} & l_{31}\cdot u_{13} + l_{32}\cdot u_{23} + l_{33} \end{bmatrix}$$

(1) (2) (3) (4) (5)

$$\begin{cases} l_{11} = 2 \\ l_{21} = 4 \\ l_{31} = 2 \end{cases} \quad \begin{cases} l_{11}\cdot u_{12} = -1 \Rightarrow u_{12} = -\frac{1}{2} \\ l_{11}\cdot u_{13} = 3 \Rightarrow u_{13} = \frac{3}{2} \\ \text{etc.} \end{cases}$$

for $p = 1:n$

$$l_{ip} = a_{ip} - \sum_{k=1}^{p-1} l_{ik}\cdot u_{kp}, \quad i = p:n$$

$$u_{pj} = \frac{1}{l_{pp}}\left(a_{pj} - \sum_{k=1}^{p-1} l_{pk}\cdot u_{kj}\right), \quad j = p+1:n$$

III.b) Dolittle $l_{ii} = 1$

for $p = 1:n$

$$u_{pj} = a_{pj} - \sum_{k=1}^{p-1} l_{pk}\cdot u_{kj}, \quad j = p:n$$

$$l_{ip} = \frac{1}{u_{pp}}\left(a_{ip} - \sum_{k=1}^{p-1} l_{ik}\cdot u_{kp}\right), \quad i = p+1:n$$

III. c) Cholesky $L = U^T$

Condiții: 1. A - simetrică

2. A - pozitiv definită sau măcar semi-pozitiv definită

A - poz def. → suficient ca toți det. stânga sus > 0

$$A = \begin{bmatrix} 3 & 4 \\ 4 & 6 \end{bmatrix} \quad \det([3]) > 0 \quad \det\left(\begin{bmatrix} 3 & 4 \\ 4 & 6 \end{bmatrix}\right) > 0$$

A - semipoz. def → suficient ca $a_{ii} \geq 0 + |a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ij}|$

$$A = \begin{bmatrix} -18 & 2 & 5 \\ 3 & 7 & 4 \\ 1 & 0 & 5 \end{bmatrix} \quad \begin{matrix} |-18| \geq |2|+|5| \\ |7| \geq |3|+|4| \\ |5| \geq |1|+|0| \end{matrix}$$

A - diagonal dominantă

Ex: $A = \begin{bmatrix} 14 & 8 & 3 \\ 8 & 5 & 2 \\ 3 & 2 & 1 \end{bmatrix} = L \cdot U = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \cdot \begin{bmatrix} l_{11} & l_{21} & l_{31} \\ 0 & l_{22} & l_{32} \\ 0 & 0 & l_{33} \end{bmatrix}$

$$= \begin{bmatrix} l_{11}^2 & l_{11} \cdot l_{21} & l_{11} \cdot l_{31} \\ l_{21} \cdot l_{11} & l_{21}^2 + l_{22}^2 & l_{21} \cdot l_{31} + l_{22} \cdot l_{32} \\ l_{31} \cdot l_{11} & l_{31} \cdot l_{21} + l_{32} \cdot l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix}$$

for $i = 1:n$

  for $j = 1:i-1$

$$l_{ij} = \frac{1}{l_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} \cdot l_{jk} \right)$$

  endfor

$$l_{ii} = \sqrt{a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2}$$

N. Inversarea matricelor prin met. partiționării

$$A = \begin{bmatrix} A_1 & A_3 \\ A_2 & A_4 \end{bmatrix} \qquad X = A^{-1} = \begin{bmatrix} X_1 & X_3 \\ X_2 & X_4 \end{bmatrix}$$

$$A \cdot A^{-1} = \begin{bmatrix} A_1 & A_3 \\ A_2 & A_4 \end{bmatrix} \cdot \begin{bmatrix} X_1 & X_3 \\ X_2 & X_4 \end{bmatrix} = \begin{bmatrix} I & 0 \\ 0 & I \end{bmatrix}$$

$$X_1 = (A_1 - A_3 \cdot A_4^{-1} \cdot A_2)^{-1}$$

$$X_2 = -A_4^{-1} \cdot A_2 \cdot X_1$$

$$X_3 = -A_1^{-1} \cdot A_3 \cdot X_4$$

$$X_4 = (A_4 - A_2 \cdot A_1^{-1} \cdot A_3)^{-1}$$

Lab 3 MN - Norme. Matrice ortogonală

I. Norme de vectori și matrici

$$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p\right)^{1/p}$$

$$\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|$$

Vectori:

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

$$\|x\|_\infty = \max |x_i|$$

Matrici:

- Frobenius $\|A\|_F = \sqrt{\sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij}^2}$
- Max $\|A\|_\infty = \|A\|_{max} = \max\{|a_{ij}|\}$
- p-norm $\|A\|_p = \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = \max_{\|x\|_p = 1} \|Ax\|_p$

↳ maximum relative expansion by A

Prod. scalar

$$\langle x, y \rangle = \sum_{i=1}^{n} x_i \cdot y_i = y^T \cdot x \quad (\text{octave } \text{dot}(x, y))$$

$$\|x\|_2 = \sqrt{\langle x, x \rangle}$$

x, y ortogonali $\Rightarrow \langle x, y \rangle = 0$

x, y ortonormală $\Rightarrow \begin{cases} \langle x, y \rangle = 0 \\ \|x\| = 1, \ \|y\| = 1 \end{cases}$

H-ortogonală dacă toți vectorii coloană sunt ortonormali

Prop: 1. $H^T \cdot H = H \cdot H^T = I$

2. $H^{-1} = H^T$

3. $\|Hx\|_2 = \|x\|_2$

4. $\|HA\|_2 = \|A\|$

5. $\|H\|_2 = 1$

6. $\det(H) = \pm 1$

II Factorizare QR

$Ax=b$

$A=QR$ → superior Δ

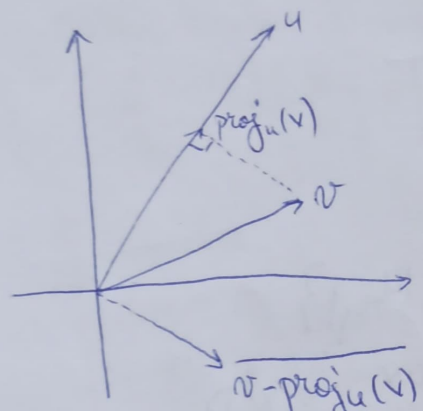
↓ ortogonală

$\Rightarrow QRx=b \Rightarrow Rx=Q^{-1}\cdot b=Q^T\cdot b$

1) Factorizarea Gram-Schmidt

Normarea lui $v \rightarrow \frac{v}{\|v\|}$

Proiecția ortogonală a vectorului v pe baza u $proj_u(v)=\frac{<v,u>}{<u,u>}\cdot u$



$\{\vec{u}, \vec{v}-proj_{\vec{u}}(\vec{v})\}$ - bază ortogonală

Formulă Gram-Schmidt pt. calcul manual

for $i=1:n$

$u_i = \underbrace{a(:,i)}_{\text{coloana } i} - \sum_{k=1}^{i-1} proj_{u_k}(a(:,i))$

$e_i = \frac{u_i}{\|u_i\|}$

$proj_{u_k}(a(:,i)) = <a(:,i), e_k>\cdot e_k$

$e_1, e_2 \dots, e_n$ coloanele matricei ortogonale Q

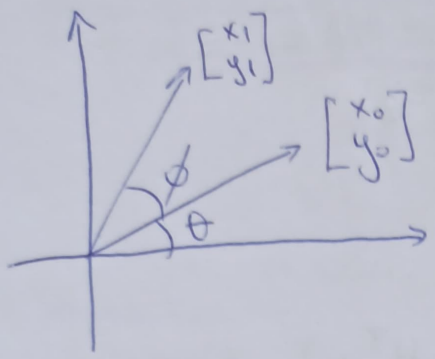
$R = Q^T\cdot A$

Pt. Octave:

```
for j=1:n
  for i=1:j-1
    R(i,j) = Q(:,i)' * A(:,j);
  endfor
  S = zeros(m,1)
  for i=1:j-1
    S = S + R(i,j) * Q(:,i);
  endfor
  aux = A(:,j) - S
  R(j,j) = norm(aux,2);
  Q(:,j) = aux/R(j,j);
endfor
```

2) Factorizarea Givens

- Rotirea vectorilor folosind matrici 2D de transformare



$$x_1 = x_0 \cdot \cos\phi + y_0 \cdot \sin\phi$$
$$y_1 = x_0 \cdot \sin\phi + y_0 \cdot \cos\phi$$
$$\begin{bmatrix} \cos\phi & -\sin\phi \\ \sin\phi & \cos\phi \end{bmatrix} \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} = \begin{bmatrix} x_1 \\ y_1 \end{bmatrix}$$

↓ matricea de rotire stânga cu ϕ

- Cum creăm 0-uri prin rotiri 2D?

$$\begin{bmatrix} c & -s \\ s & c \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} r \\ 0 \end{bmatrix} \qquad r = \left\| \begin{bmatrix} a \\ b \end{bmatrix} \right\| \qquad c = \frac{a}{r} \qquad s = \frac{-b}{r}$$

- Formula:

```
for i = 2:n
    for j = 1:i-1
        Eliminăm A(i,j) folosind Gij
```

$G_{ij} = I_n$ cu $\begin{matrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{matrix}$ pe liniile i,j $\qquad i > j$

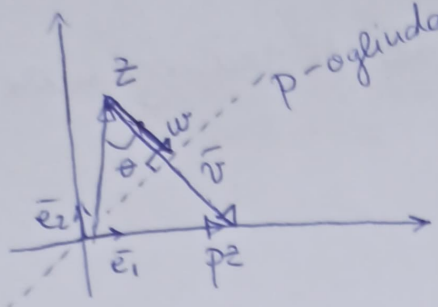
$$A(K,K) = c$$
$$A(K,l) = -s$$
$$A(l,K) = s$$
$$A(l,l) = c$$
$$r = \sqrt{A(K,K)^2 + A(l,l)^2}$$
$$c = \frac{A(K,K)}{r}$$
$$s = \frac{A(K,l)}{r}$$

$$G_{21} = \begin{bmatrix} c & -s & 0 \\ s & c & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad \begin{matrix} 1 \\ 1 \end{matrix}$$

Pt. $n=3$ ex: $G_{32} \cdot G_{31} \cdot G_{21} \cdot A = R$

$$Q^T \Rightarrow Q = G_{21}^T \cdot G_{31}^T \cdot G_{32}^T$$

3) Factorizarea Householder



$\|z\| = \|pz\|$

$pz = \|z\| \cdot \vec{e_1} = z + v \Rightarrow v = \|z\| \cdot \vec{e_1} - z$

$$P = I - \frac{2 v \cdot v^T}{v^T \cdot v}$$

$$\begin{bmatrix} x \\ x \\ x \\ x \end{bmatrix} \xrightarrow{H} \begin{bmatrix} x \\ 0 \\ 0 \\ 0 \end{bmatrix} \Rightarrow \underbrace{H_3 \cdot H_2 \cdot H_1}_{Q^T} \cdot A = R \Rightarrow Q = H_1^T \cdot H_2^T \cdot H_3^T$$

Formula:

$A \in \mathbb{R}^{m \times n}$; $R = Q^T \cdot A$, $Q^T = H_{\min(m-1,n)} \cdot \ldots \cdot H_p \cdot \ldots \cdot H_2 \cdot H_1$

$$H_p = I - 2 \frac{v_p \cdot v_p^T}{v_p^T \cdot v_p} \qquad v_p = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ v_{pp} \\ v_{mp} \end{bmatrix}$$

$v_{pp} = a_{pp} + \sigma_p$

$\sigma_p = \pm \operatorname{sign}(a_{pp}) \cdot \|a_{p:m,p}\|$

$v_{ip} = a_{ip} \quad i > p$

Ex: $A = \begin{bmatrix} 2 & 4 \\ 1 & 3 \\ 2 & 2 \end{bmatrix}$ $V_1 = \begin{bmatrix} v_{11} \\ v_{12} \\ v_{13} \end{bmatrix} \begin{matrix} -a_{11} + \sigma_1 \\ -a_{12} \\ -a_{13} \end{matrix}$, $\sigma_1 = \operatorname{sign}(a_{11}) \cdot \left\| \begin{matrix} 2 \\ 1 \\ 2 \end{matrix} \right\| = 3 \Rightarrow V_1 = \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix}$

$$H_1 = I - 2 \frac{V_1 \cdot V_1^T}{V_1^T \cdot V_1} = I - 2 \cdot \begin{bmatrix} 25 & 5 & 10 \\ 5 & 1 & 2 \\ 10 & 2 & 4 \end{bmatrix} / 30 = \begin{bmatrix} -2/3 & -1/3 & -2/3 \\ -1/3 & 14/15 & -2/15 \\ -2/3 & -2/15 & 11/15 \end{bmatrix}$$

$$H_1 \cdot A = \begin{bmatrix} -3 & -5 \\ 0 & \begin{bmatrix} 6/5 \\ -8/5 \end{bmatrix} \\ 0 & \end{bmatrix}$$

$V_2 = \begin{bmatrix} 0 \\ v_{22} \\ v_{32} \end{bmatrix} \begin{matrix} \\ -a_{22} + \sigma_2 \\ -a_{32} \end{matrix}$ $\sigma_2 = \operatorname{sign}(a_{22}) \cdot \left\| \begin{matrix} 6/5 \\ -8/5 \end{matrix} \right\| = 2 \Rightarrow V_2 = \begin{bmatrix} 0 \\ 16/5 \\ -8/5 \end{bmatrix}$

$$H_2 = I - 2 \frac{v_2 \cdot v_2^T}{v_2^T \cdot v_2} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -3/5 & 4/5 \\ 0 & 4/5 & 3/5 \end{bmatrix} \Rightarrow \underbrace{H_2 \cdot H_1}_{Q^T} \cdot A = \begin{bmatrix} -3 & -5 \\ 0 & -2 \\ 0 & 0 \end{bmatrix} = R \Rightarrow Q = H_1^T \cdot H_2^T$$

Lab 4 MN - Eliminare Gaussiană

I. Eliminare Gaussiană (G)

- op. elementare: 1) interschimbarea rândurilor
  2) înmulțirea unei linii cu un scalar
  3) adăugarea rândurilor scalate

Se fac 0 elem. de sub diagonală

Formulă:

for $p = 1 : n-1$

  for $i = p+1 : n$

$$L_i \leftarrow L_i - \frac{a_{ip}}{a_{pp}} \cdot L_p$$

Ex: $\bar{A} = \left[\begin{array}{ccc|c} \textcircled{2} & 1 & 7 & 3 \\ 3 & 1 & 0 & 2 \\ 5 & 1 & 4 & 4 \end{array}\right] \xrightarrow[L_3 - \frac{5}{2}L_2]{L_2 - \frac{3}{2}L_1} \left[\begin{array}{ccc|c} 2 & 1 & 7 & 3 \\ 0 & \textcircled{-1/2} & -21/2 & -5/2 \\ 0 & -3/2 & -27/2 & -7/2 \end{array}\right] \xrightarrow{L_3 - \frac{-3/2}{-1/2} \cdot L_2} \left[\begin{array}{ccc|c} 2 & 1 & 7 & 3 \\ 0 & -1/2 & -21/2 & -5 \\ 0 & 0 & 18 & 4 \end{array}\right]$ SST

Probleme: 1) împărțim la 0 $\left[\begin{array}{ccc|c} \textcircled{0} & 1 & 2 & 2 \\ 3 & 1 & 5 & 2 \\ 7 & 1 & 1 & 3 \end{array}\right]$ nu putem împărți la pivot

2) erori la rotunjire

II. Eliminare Gaussiană cu pivotare parțială (GPP)

Cel mai mare nr. în modul de pe coloană devine pivot

$$\bar{A} = \left[\begin{array}{ccc|c} 0 & 1 & 3 & 3 \\ 2 & 1 & 3 & 1 \\ \textcircled{-3} & 1 & 1 & 1 \end{array}\right] \xrightarrow{L_1 \overset{\sim}{\leftrightarrow} L_3} \left[\begin{array}{ccc|c} -3 & 1 & 1 & 1 \\ 2 & 1 & 3 & 1 \\ 0 & 1 & 3 & 3 \end{array}\right] \xrightarrow{L_2 - \frac{2}{-3}L_1} \left[\begin{array}{ccc|c} -3 & 1 & 1 & 1 \\ 0 & \textcircled{5/3} & 11/3 & 5/3 \\ 0 & 1 & 3 & 3 \end{array}\right] \xrightarrow{L_3 - \frac{1}{5/3}L_2}$$

$$\rightarrow \left[\begin{array}{ccc|c} -3 & 1 & 1 & 1 \\ 0 & 5/3 & 11/3 & 5/3 \\ 0 & 0 & 4/5 & 2 \end{array}\right]$$

for $p = 1 : n-1$

  $L_p \overset{\sim}{\leftrightarrow} L_k$ cu $|a_{kp}| \geq |a_{ip}|$, $\forall\, i \geq p$, $k \geq p$

  for $i = p+1 : n$

    $L_i \leftarrow L_i - \frac{a_{ip}}{a_{pp}} \cdot L_p$

Probleme: 1) Variația elem de pe aceeași linie → erori rotunjire

III. Elim. Gaussiană cu pivotare parțială scalată (GPPS)

for $p = 1 : n-1$ (căutăm maxim relativ pentru linia lui pe coloana de sub diagonală)

$s_i = \max |a_{ij}|, \; i \geq p$ — factorii scalari ai liniei i

$j = p : n$

$L_p \rightleftarrows L_k$ cu $\frac{|a_{kp}|}{s_k} \geq \frac{|a_{ip}|}{s_i} \; \forall i \geq p, k \geq p$

for $i = p+1 : n$

$L_i \leftarrow L_i - \frac{a_{ip}}{a_{pp}} \cdot L_p$

IV. Eliminare Gaussiană cu pivotare totală

for $p = 1 : n-1$ (căutăm max din matrice și îl punem pivot)

$L_p \rightleftarrows L_k$, $C_p \rightleftarrows C_k$ $|a_{kk}| \geq |a_{ij}| \; \forall i, j \geq p$

for $i = p+1 : n$

$L_i \leftarrow L_i - \frac{a_{ip}}{a_{pp}} \cdot L_p$

Lab 5 MN - Metode iterative

$Ax=b$
$A=N-P$ $\Rightarrow (N-P)x=b \Rightarrow Nx=Px+b$

iterație $Nx_{k+1}=P\cdot x_k+b \Rightarrow x_{k+1}=N^{-1}\cdot P\cdot x_k+N^{-1}\cdot b$

Not. $G=N^{-1}\cdot P$ - matrica de iterație

$c=N^{-1}\cdot b$ - vector de iterație $\rightarrow x_{k+1}=Gx_k+c$

Condiția de convergență: $\rho(G)<1$, unde $\rho(G)=\max|\lambda_i|$

↳ raza spectrală a matricii G

Alegerea lui N:

1) Partea diag. a lui A (Jacobi)
2) Partea inf. str. a lui A (Gauss-Seidel)
3) O combinație între 1 și 2 (Suprarelaxării)

$\rho(G)\nearrow 1 \rightarrow$ converge lent

$\rho(G)\searrow 0 \rightarrow$ converge rapid

1. Met. Jacobi

$$\begin{bmatrix}2&1\\3&4\end{bmatrix}=\begin{bmatrix}2&0\\0&4\end{bmatrix}+\begin{bmatrix}0&0\\3&0\end{bmatrix}+\begin{bmatrix}0&1\\0&0\end{bmatrix}$$

$A = D + L + U$

$$\begin{cases}N=D\\P=N-A=-L-U\end{cases}$$

Forma matriceală ↑

$N^{-1}\cdot P=G_j \rightarrow$ mat. iterație Jacobi

$N^{-1}\cdot b=c_j \rightarrow$ vect — " —

$x_{k+1}=G_j\cdot x_k+c_j$

Forma nematriceală:

$$x_{k+1}^{(i)}=\frac{b_i-\sum_{j=1,j\neq i}^{n}a_{ij}\cdot x_k^{(j)}}{a_{ii}}=\frac{b_i-\sum_{j=1}^{i-1}a_{ij}\cdot x_k^{(j)}-\sum_{j=i+1}^{n}a_{ij}\cdot x_k^{(j)}}{a_{ii}}$$

↑ ajută la Gauss-Seidel

II. Gauss - Seidel

Forma matriceală:

$$\begin{cases} N = D + L \\ P = -U \end{cases}$$

Forma nematriceală:

$$x_{k+1}^{(i)} = \frac{b_i - \sum_{j=1}^{i-1} a_{ij} \cdot x_{k+1}^{(j)} - \sum_{j=i+1}^{n} a_{ij} \cdot x_k^{(j)}}{a_{ii}}$$

III. Suprarelaxare (SOR) - Successive over relaxation

Forma mat.:

$$\begin{cases} N = D + \omega L \\ P = (1-\omega)D - \omega U \end{cases}$$

$$A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \Rightarrow N = \begin{bmatrix} 2 & 0 \\ -\omega & 2 \end{bmatrix} \Rightarrow P = \begin{bmatrix} 2(1-\omega) & \omega \\ 0 & 2(1-\omega) \end{bmatrix}$$

$$N^{-1} \cdot P = G_{SOR}$$

$$\omega N^{-1} \cdot b = c_{SOR}$$

Forma nemat.:

$$x_{k+1}^{(i)} = (1-\omega) \cdot x_k^{(i)} + \omega \cdot \underbrace{\frac{b_i - \sum_{j=1}^{i-1} a_{ij} \cdot x_{k+1}^{(j)} - \sum_{j=i+1}^{n} a_{ij} \, x_k^{(j)}}{a_{ii}}}_{\text{Gauss - Seidel}}$$

Alegerea lui $\omega \in (0,2)$

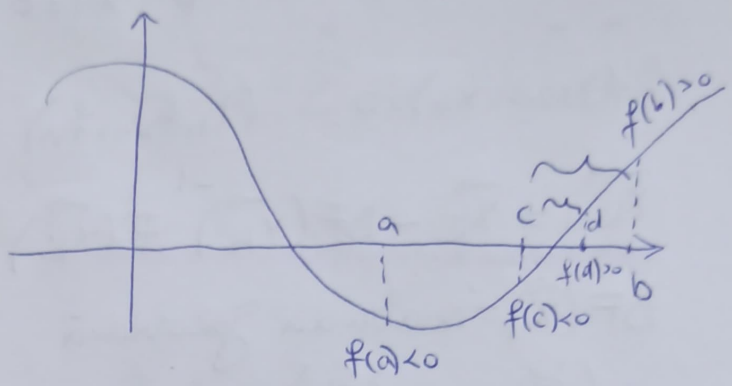
- $\omega = 1 \rightarrow$ Gauss - Seidel
- $\omega < 1 \rightarrow$ subrelaxare
- $\omega > 1 \rightarrow$ suprarelaxare

Lab 6 - Soluții ale ec. neliniare

Încercăm să găsim o rădăcină r a unei funcții $f(x)=0$

I. Metoda bisecției

(seamănă cu căutarea liniară)



f - continuă

Fie a,b a.î. $f(a)\cdot f(b)<0$ $\Big| \Rightarrow$

$\Rightarrow \exists\, r\in(a,b)$ a.î. $f(r)=0$

Fie $c=\frac{a+b}{2}$; Dacă $f(c)\cdot f(a)<0 \Rightarrow r\in(a,c)$ ← noul b

Dacă $f(c)\cdot f(b)<0 \Rightarrow r\in(c,b)$ ← noul b

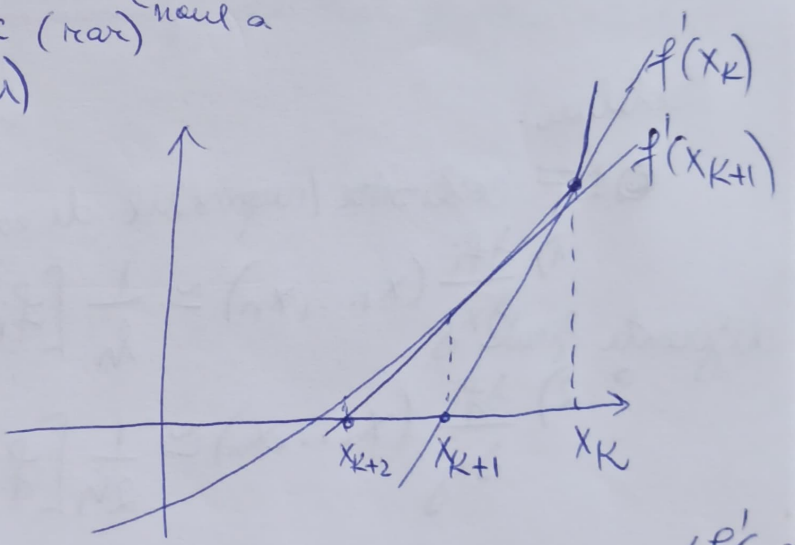
Dacă $f(c)=0 \Rightarrow r=c$ (rar) ← noul a

II. Metoda tangentei (Newton-Raphson)

f - cont. și derivabilă

$$f'(x_k)=\frac{y_2-y_1}{x_2-x_1}=\frac{f(x_k)-0}{x_k-x_{k+1}}$$

$$x_{k+1}=x_k-\frac{f(x_k)}{f'(x_k)}$$

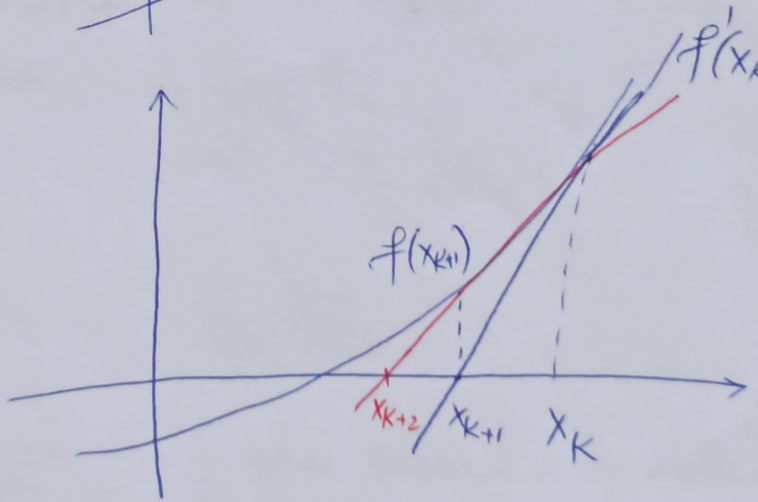


III. Metoda secantei

Evită să calc. $f'(x)$

Aprox. $f'(x_{k+1})$ ca secanta ce trece prin $(x_k, f(x_k))$ și $(x_{k+1}, f(x_{k+1}))$

$$f'(x_{k+1})=\frac{f(x_k)-f(x_{k+1})}{x-x_{k+1}}$$



$$x_{k+2}=x_{k+1}-\frac{f(x_{k+1})}{f'(x_{k+1})}=x_{k+1}-\frac{x_k-x_{k+1}}{f(x_k)-f(x_{k+1})}\cdot f(x_{k+1})=x_{k+2}$$

IV. Metoda Newton pt. sisteme neliniare

$f_1(x_1 \dots x_n) = 0$

$f_2(x_1 \dots x_n) = 0$ $\Rightarrow F(\vec{x}) = 0$

$\dots$

$f_n(x_1 \dots x_n) = 0$ $\quad (f_1, f_2 \dots, f_n)$

$\vec{x} \to \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n$

$$\vec{x}_{k+1} = \vec{x}_k - DF(\vec{x}_k)^{-1} \cdot F(\vec{x}_k) \qquad \vec{x}_i \in \mathbb{R}^n \qquad F = (f_1 \dots f_n)$$

$DF(\vec{x})$ = matricea Jacobiană

$$= \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \dots & \frac{\partial f_2}{\partial x_n} \\ \vdots & & \\ \frac{\partial f_n}{\partial x_1} & \dots & \frac{\partial f_n}{\partial x_n} \end{pmatrix}$$

Pt. a nu calcula $DF(\vec{x}_k)^{-1}$

$$\underbrace{DF(\vec{x}_k)}_{A}\underbrace{(\vec{x}_{k+1} - \vec{x}_k)}_{\Delta x} = \underbrace{-F(\vec{x}_k)}_{b}$$

$\Downarrow$

$\vec{x}_{k+1} = \vec{x}_k + \Delta x$ (aflat din $Ax = b$)

Probleme:

- DF costisitoare / imposibil de calculat $\Rightarrow$ se aproximează

1) $\frac{\partial f_i}{\partial x_j}(x_1 \dots x_n) \simeq \frac{1}{h}\left[f_i(x_1 \dots, x_j + h, \dots, x_n) - f_i(x_1 \dots, x_n)\right]$ diferențe finite

2) $\frac{\partial f_i}{\partial x_j}(x_1 \dots x_n) \simeq \frac{1}{2h}\left[f_i(x_1 \dots, x_j + h, \dots x_n) - f_i(x_1 \dots, x_j - h, x_n)\right]$

unde $h > 0$ f. mic

Lab 7 - Vectori și valori proprii

I. Val. și vect. proprii

$p(\lambda) = \det(A - \lambda I)$

$p(\lambda) = 0$ - ec. caract.

$\lambda(A) = \{\lambda_1, \dots, \lambda_n\}$ - spectrul lui A

$\rho(A) = \max|\lambda_i|$ - raza spectrală

Prop:

$\sum_{i=1}^{n} \lambda_i = \sum_{i=n}^{n} a_{ii} = \text{trace}(A)$

$\prod_{i=1}^{n} \lambda_i = \det(A)$

$A^k \cdot x_i = \lambda_i^k \cdot x_i$

II. Metoda puterii (directe) MPD

/dominantă

Determină cea mai mare val. proprie și vectorul său propriu folosind o aproximare inițială a unui vect. propriu

Când găsim un vector suficient de apropiat de vect. propriu căutat, calc. val. proprie $\lambda_n = x_n^T \cdot A \cdot x_n$

Alg: se dă A, x_0, [illegible]

vect. random

```
prev_x = x0
while 1
    x = A * prev_x;
    x = x / norm(x);
    lambda = x' * A * x;
    if err indeplinit
        return
    endif
    prev_x = x
```

III. Met. puterii inverse MPI

Det. cea mai mică val. proprie și vect. său propriu folosind o aproximare inițială a unui vector propriu și A^{-1} în loc de A.

Algoritmul e la fel ca MPD, doar că aveam $x = A^{-1} \cdot prev_x$, unde pe A^{-1} îl calculăm cu metodele învățate

III. Metoda puterii inverse deplasate MPID

Calc. cea mai apropiată val proprie de un α dat și vect. săi proprii.

Alg: Se dă A, x_0, α
(x_0 ↑ random; α ↑ aproximarea unei val. proprii)

prev_x = x_0
while 1
    $x = (A - \alpha J)^{-1} \cdot$ prev_x;
    x = x/norm(x);
    lambda = $x^t \cdot A \cdot x$;
    α = lambda;
    if err îndeplinită
        return
    endif
    prev_x = x;

Lab 8

I. Met. puterii ortogonalizată

A-simetrică $\in \mathbb{R}^{n \times n}$

$x, y \in \mathbb{R}^n$

Dacă (λ, x) și (μ, y) - perechi de val-vect. pr. pt. A și $\lambda \neq \mu$,

A sim. $\Rightarrow \langle x, y \rangle = 0 \Rightarrow x, y$ - ortogonali

1) Calc. x_1 cu MPD ved. pr. asoc. val. pr. dominantă
2) Ștergem proiecția pe $\text{span}\{\vec{x_1}\}$ a unui u_0 random $\Rightarrow$
3) Calc. x_2 cu MPD
   și așa mai departe până le găsim pe toate
4) Ștergem proiecția pe $\text{span}\{x_1, x_2\}$ a unui u_0 random ...

→ iterare + ortogonalizare față de vect. pr. descoperiți la pași anteriori

1) $u_0^{(1)}$ = vect random normat, $u_1^{(1)} = \frac{Au_0^{(1)}}{\|Au_0^{(1)}\|}$, $u_2^{(1)} = \frac{Au_1^{(1)}}{\|Au_1^{(1)}\|}$ ... $\longrightarrow x_1$

2) $u_0^{(2)}$ = vect. random normat
   $u_0^{(2)} = u_0^{(2)} - x_1^T \cdot u_0^{(2)} \cdot x_1$ → ștergem componenta x_1 din $u_0^{(2)}$
   $u_1^{(2)} = \frac{Au_0^{(2)}}{\|Au_0^{(2)}\|} \longrightarrow x_2$

i) $u_0^{(i)}$ = vect. random normat
   $u_0^{(i)} = u_0^{(i)} - \sum_{j=1}^{i-1} x_j^T \cdot u_0^{(i)} \cdot x_j$ → ștergem comp. $x_1 \ldots, x_{i-1}$ din $u_0^{(i)}$
   $u_1^{(i)} = \frac{Au_0^{(i)}}{\|Au_0^{(i)}\|} \rightarrow x_i$

În practică, trb. să ștergem proiecția și pe $u_1^{(i)}, u_2^{(i)} \ldots$ (ortogonalizare făcută la fiecare pas)

```
for i=1:n  //pt. fiecare val/vect. propriu din A aplicăm ~~met~~ MPS
    prev_x=rand(n,1); //V0 random
    while 1
        for j=1:i-1
            prev_x -= X(:,j)' * prev_x * X(:,j); //ortogonalizare
        //met. puterii:
        x= A*prev_x;
        x = x/norm(x);
        lambda = x' * A * x;
        if err indeplinită
            return
        prev_x = x
```

! Doar mat. simetrice

Gram-Schmidt combinat cu MPS

II. Iterare ortogonală

Facem orice factorizare QR în loc de Gram-Schmidt. + nu așteptăm $\overline{x_1}$ înainte să facem $\overline{x_2}$

Matrice de vect. random $U^{(0)} = [U_1 | U_2 | .. | U_n]$

for $K = 1, 2 ...$

$Q^{(K)} R^{(K)} \leftarrow U^{(K-1)}$

$U^{(K)} \leftarrow A \cdot Q^{(K)}$ → am ortogonalizat $U^{(K-1)}$

↳ aplic MPS pe toți vectorii simultan

La final, U va conține vect. pr. neortogonalizați $\Rightarrow [Q, R] = qr(U)$

$\Rightarrow$ Q - vect. pr. ortog.

R - val. pr. pe diag.

III. Deflație – pt. matrici nesimetrice

$(\lambda_1, \bar{x}_1)$ – pereche val-vect. pr. pt. A

$H \cdot \bar{x}_1 = \bar{e}_1$

↑ reflector Householder

$HAH^T \cdot \bar{e}_1 = \lambda_1 \cdot \bar{e}_1 \Rightarrow (\lambda_1, \bar{e}_1)$ – pereche val-vect. pr. pt. HAH^T

$$HAH^T = \begin{pmatrix} \lambda_1 & x\ x\ x\ \dots \\ 0 & \\ \vdots & B \\ 0 & \end{pmatrix} \qquad \lambda(B) = \lambda(HAH^T) \setminus \{\lambda_1\}$$
$$\lambda''(A)$$

1) MPD → λ_1, x_1
2) Construim H a.î. $H\bar{x}_1 = \bar{e}_1$
3) Găsim $B = HAH^T(2{:}end, 2{:}end)$
4) Repetăm

Alg:

$A0 = A$; //reținem matricea inițială

for $i = 1:n$; $\in \mathbb{R}^{n-i+1}$

$(\lambda_i, x_B) = MPD(A, \dots)$

$(\lambda_i, x_i) = MPID(A0, \lambda_i \dots)$ → x // aflăm x_i cu n coloane

→ $\in \mathbb{R}^n$

$X = [x, x_i]$

$l = [l, \lambda_i]$

H = reflector care elimină totul sub primul el. al lui $\bar{x}_B$ / îl duce pe $\bar{x}_B$ în $\bar{e}_1$

$H = \underline{I} - \frac{2 v \cdot v^T}{v^T \cdot v}$, unde $\begin{cases} v = x_B \\ v(1) \mathrel{+}= -sign(x_B(1)) \cdot \|x_B\| \end{cases}$ → ajungem în e_1

$A = H^T A H$

$A = A(2{:}end, 2{:}end)$

IV. Alg. QR "fără deplasare"

1) A-simetrică

for $k=1,2\ldots$

$Q^{(k)} \cdot R^{(k)} \leftarrow A^{(k)}$

$A^{(k+1)} \leftarrow R^{(k)} \cdot Q^{(k)}$

La final, A-diag. cu val. pr. pe diag.

2) A-nesimetrică

același alg. $\Rightarrow$ A converge la matrice cvasi-superior Δ (forma Schur)

Ex: $S = \begin{bmatrix} \textcircled{1} & x & x & x \\ 0 & \boxed{2} & \boxed{-3} & x \\ 0 & \boxed{3} & \boxed{2} & x \\ 0 & 0 & 0 & \textcircled{5} \end{bmatrix}$ $1 \in \lambda(A)$, $5 \in \lambda(A)$, $\lambda\begin{pmatrix} 2 & -3 \\ 3 & 2 \end{pmatrix} \subset \lambda(A)$

$\downarrow$ $2+3i, 2-3i \Rightarrow \lambda(A) = \{1, 5, 2+3i, 2-3i\}$

V. Accelerare computațională a alg. QR fără deplasare

1) A-sim.

→ Reducem A la tridiagonală cu Householder

→ QR fără deplasare pe A-tridiag. $\Rightarrow$ A-diag.

2) A-nesim

- Dacă A ar fi Hessenberg superioară (superior Δ + încă un rând de sub diag. cu val. nenule)

→ reducem A la Hessenberg sup. cu Householder

→ QR fără deplasare pe A-Hessenberg $\Rightarrow$ A-forma Schur